原著論文 Original Paper

適応的実数値交叉 AREX の提案と評価

Proposal and Evaluation of Adaptive Real-coded Crossover AREX

秋本 洋平 Youhei Akimoto
東京工業大学大学院 総合理工学研究科
Interdisciplinary Graduate School of Science and Engineering, Tokyo Institute of Technology
akimoto@fe.dis.titech.ac.jp

永田 裕一 Yuichi Nagata
（同　上）
nagata@dis.titech.ac.jp

佐久間 淳 Jun Sakuma
筑波大学大学院 システム情報工学研究科
Graduate School of Systems and Information Engineering, University of Tsukuba
jun@cs.tsukuba.ac.jp

小野 功 Isao Ono
東京工業大学大学院 総合理工学研究科
Interdisciplinary Graduate School of Science and Engineering, Tokyo Institute of Technology
isao@dis.titech.ac.jp

小林 重信 Shigenobu Kobayashi
（同　上）
kobayasi@dis.titech.ac.jp

keywords: function optimization, adaptation of expansion rate, crossover mean descent, adaptive real-coded ensemble crossover

Summary

Since once premature convergence happens evolutionary algorithms for function optimization can no longer explore areas of the search space and fail to find the optimum, it is required to handle the notorious drawback. This paper proposes two novel approaches to overcome premature convergence of real-coded genetic algorithms (RCGAs). The first idea is to control the sampling region of crossover by adaptation of expansion rate. The second idea is to cause the acceleration of the movement of population by descending the mean of crossover. Finally, we propose a crossover that combines the adaptation of expansion rate technique and the crossover mean descent technique, called AREX (adaptive real-coded ensemble crossover). The performance of the real-coded GA using AREX is evaluated on several benchmark functions including functions whose landscape forms ridge structure or multi-peak structure, both of which are likely to lead to the miserable convergence phenomenon. The experimental results show not only that the proposed method can locate the global optima of functions on which it is difficult for the existing GAs to discover it but also that our approach outperforms the existing one in number of function evaluations on all functions. Our approach enlarges the classes of functions that real-coded GAs can solve.

1. は じ め に

実関数 $f(\boldsymbol{x})$ の最小値または最大値を与える変数値 $\boldsymbol{x}^*$ を求める問題を関数最適化問題と言う．関数最適化問題は工学，科学の様々な場面においてしばしば現れる重要な問題の一つである．

進化的アルゴリズムは定義域内に複数の局所的最適解を有する多峰性関数を含む多くの問題クラスについて効果的な手法であることが知られている．実数値 GA (real-coded genetic algorithms, [Eshelman 93]) は関数最適化問題に対する有望な進化的解法の一つである．

初期収束 (premature convergence) は実数値 GA に限らず GA が抱える問題点の一つである．初期収束とは，大域的最適解付近を十分に探索する前に，集団が局所的最適解もしくは局所的最適解ですらない場所に誤って収束してしまう現象であり，実問題においてしばしば観察される．初期収束は稜構造や多峰性といった景観を有する関数の最適化において特に観察されており，この現象を回避するために様々な手法が提案されている．その一つは [Ono 99a, 佐久間 02, 佐久間 04] で提案されているように，性質の異なる複数の探索オペレータを組み合わせる方法である．また別のアプローチとして [Takahashi 00] では多様性の維持に優れた世代交代モデルを使用する方法，[染谷 01, Tsutsui 00] では問題の境界に関する事前知識を活用する方法などが提案されている．しかし，これらの方法は特定の問題領域でしか効果を発揮せず，初期収束を起こしやすい上述二つの関数景観のどちらにも効果的な方法ではない．交叉 REX^{star} [小林 09] は交叉のみで稜構造や多峰性の関数において効果を発揮しているが，回転不変性を犠牲にしているため変数間依存のある関数の最適化において探索性能が著しく低下する．悪スケールで変数間依存があるような一般的な問題領域で有効であり，稜構造と多峰性のどちらの関数景観にも効果的な方法は提案されていないのが現状である．

本論文の目的は，悪スケール性や変数間依存性のある関数において有効で，稜構造関数や多峰性関数の最適化において発生する初期収束を回避するメカニズムを提案することである．本論文では二つの方法を提案する．一つ目の方法は，交叉の拡張率 (子個体生成領域の広がり) を適応的に調節し，集団の多様性をコントロールすることで重心移動中の初期収束を回避するものである．二つ目の方法は，交叉中心を有望領域にシフトし，有望な個体を生成しやすくすることで初期収束を回避する方法である．前者は CMA-ES (Evolution Strategy with Covariance Matrix Adaptation, [Hansen 06]) における step-size adaptation [秋本 09, Ostermeier 94] に，後者は交叉 REX^{star} に着想を得た方法である．本論文ではこれら二つの方法を組み合わせた新しい実数値交叉を提案する．

以下，2 章では近年提案され，優れた性能が報告されている交叉 REX (real-coded ensemble crossover，[小林 09]) と世代交代モデル JGG (just generation gap，[秋本 07]) を組み合わせた実数値 GA を紹介する．3 章では実数値 GA が初期収束を起こしやすい景観を挙げ，これに対する既存研究とその問題点を述べる．初期収束を回避するために，4 章では交叉の拡張率適応を，5 章では交叉の中心降下を，それぞれ提案し，6 章ではこれらをまとめて新しい交叉 AREX (adaptive real-coded ensemble crossover) を提案する．7 章ではベンチマーク関数を用いた実験により，提案手法は初期収束を効果的に回避し，また，探索効率を改善することを示す．最後に 8 章 で本論文を取りまとめる．

2. 実 数 値 GA

GA は集団ベースの確率的多点探索手法である．実数値 GA では一つ一つの解 $\boldsymbol{x}$ (個体) を n 次元列ベクトルとして保持する．個体集団内から必要な数だけ個体 (親個体) を選択し (複製選択)，交叉オペレータによって新たな解 (子個体) を生成する．その後，子個体と親個体の中から生存する個体を決定し (生存選択)，次世代の集団を形成する．これを繰り返すことで集団は有望領域に収束していく．複製選択と生存選択はあわせて世代交代モデルと呼ばれ，実数値 GA は世代交代モデルと交叉オペレータの組合せによってアルゴリズムの性能が決まる．

本章では実数値交叉の設計指針 [Kita 99] の一つである統計量の遺伝について説明し，優れた実数値 GA の一つである交叉 REX と世代交代モデル JGG を組み合わせた方法を紹介する．

2·1 統計量の遺伝

統計量の遺伝は，交叉によって生成される子個体は親個体の平均ベクトルと共分散行列を保存すべきであるとするものである．親個体 $\boldsymbol{y}_1,\ldots,\boldsymbol{y}_\mu$ から生成される子個体と同一分布に従う確率変数を X とすると，統計量の遺伝に従う交叉は以下の二式を満たす．

$$\mathrm{E}[X]=\boldsymbol{m}=\frac{1}{\mu}\sum_{j=1}^{\mu}\boldsymbol{y}_j\ , \tag{1}$$

$$\mathrm{Cov}[X]=\frac{1}{\mu-1}\sum_{j=1}^{\mu}(\boldsymbol{y}_j-\boldsymbol{m})(\boldsymbol{y}_j-\boldsymbol{m})^{\mathrm{T}}\ , \tag{2}$$

ここで，$\mathrm{E}[X]$ は X の平均ベクトル，$\mathrm{Cov}[X]=\mathrm{E}[(X-\mathrm{E}[X])(X-\mathrm{E}[X])^{\mathrm{T}}]$ は共分散行列を表す*1．

目的関数がランダム関数であるとき選択圧がかからない世代交代モデル*2 と統計量の遺伝を満たす交叉を用いた場合，集団の平均ベクトルと共分散行列は世代を超えて平均的に一定となる [Someya 08]．すなわち，選択圧がかからなければ収束してしまうことはない．これに対し，子個体の共分散行列が親個体のそれよりも常に大きくなるように交叉が設計された場合には選択圧がかからない状況下で集団が発散し，収束するように選択圧がかかったとしても探索効率が悪い．逆に常に小さくなるように設計された場合には選択圧がかからない状況下で集団が収束するため収束速度は高いが，狭い領域しか探索できないため大域的探索性能が低い．したがって，統計量の遺伝は大域的探索性能と探索速度の良いトレードオフを与えることになり，実験的にその効果が確認されている [Kita 98, Tsutsui 99].

2·2 REX

REX は既存の交叉 (UNDX-m [喜多 01] や SPX [樋口 01]) を考察し，一般化したものである．交叉に参加する親数を μ，選択された親を $\boldsymbol{y}_1,\ldots,\boldsymbol{y}_\mu$，その重心を $\langle\boldsymbol{y}\rangle=(1/\mu)\sum_{j=1}^{\mu}\boldsymbol{y}_j$ とする．このとき REX は以下のように子個体を生成する．

$$\boldsymbol{x}_i=\langle\boldsymbol{y}\rangle+\alpha\sum_{j=1}^{\mu}\epsilon_{i,j}\left(\boldsymbol{y}_j-\langle\boldsymbol{y}\rangle\right)\ , \tag{3}$$

ここで，α は拡張率を表し，ϵ は平均 0，分散 σ^2 の独立同一分布に従う任意の乱数である．

REX は統計量の遺伝を満足する交叉である．式 (3) から明らかなように平均ベクトルは親個体の標本平均 $\langle\boldsymbol{y}\rangle$，共分散行列は

$$\mathrm{Cov}[X]=\alpha^2\sigma^2\sum_{j=1}^{\mu}(\boldsymbol{y}_j-\langle\boldsymbol{y}\rangle)(\boldsymbol{y}_j-\langle\boldsymbol{y}\rangle)^{\mathrm{T}} \tag{4}$$

となり，$\alpha=1$，$\sigma=\sqrt{1/(\mu-1)}$ とすれば式 (1)，式 (2) を充足する．

*1 従来，共分散行列として標本分散が考慮されてきた [樋口 01, 小林 09] が，[Someya 08] では不偏分散の意味で統計量を保存することの有意性が述べられており，本論文では後者に従った．

*2 以下で示す JGG はこれを満たす．

2·3 JGG

秋本ら [秋本 07] は実数値 GA における多親交叉の利点を主張し，それまでの二親交叉のための世代交代モデルである MGG [佐藤 97] を拡張して，多親交叉のための世代交代モデル JGG を提案した．

JGG は集団の初期化後，以下のステップを繰り返す．

複製選択 交叉に参加する親 μ 個体を集団内から一様ランダムに非復元抽出する．

子個体生成と評価 交叉による子個体生成と評価を繰り返し，実行可能個体を λ 個体生成する．

生存選択 子個体のうち評価値上位 μ 個体を集団に加える．

JGG は MGG と同様に複製選択として集団からのランダム選択を行う．生存選択は MGG と異なり，交叉に参加した親個体をすべて交代する．また，MGG のように評価値のランキングに基づくルーレット選択は行わず，評価値上位個体のみを生存させる．親個体をすべて子個体で置き換えることで，多峰性のある関数の下で局所解に陥りにくくなる．また，多親交叉では親すべてが交代するため探索効率が非常に高く，多親交叉の利点であるスケール不変性や回転不変性といった性質を活かすことができる．

2·4 他手法との関連性

関数最適化問題に対する解法は広く研究されている．実数値 GA のような確率的な近似解法は勾配情報を用いず，広い問題クラスに適用可能な方法であるが，このような近似解法にもそれぞれ特徴がある．Simulated Annearing [Locatelli 00] は多峰性関数において大域的最適性が保証されるが十分にゆっくり収束させる必要があり，現実的な時間内に実用解を発見するには至らないのが実状である．Differential Evolution [Efrén 06] は変数間依存性のない関数に対しては有効であるが，変数間依存性が強い関数では効率が悪い．PSO[Liang 06] や EDA[Bosman 08] は変数間依存性に対処し*3，単峰性関数では高い探索効率を示すが多峰性関数で局所解に捕われやすい．実数値 GA と CMA-ES [Hansen 06] はいずれも変数間依存性や悪スケール性のある関数に対処したアルゴリズムであり，対象とする問題クラスが類似している．実数値 GA は複製選択を工夫することで集団を適応的にニッチングし，騙し構造のある関数に対して有効な方法 [Oshima 09] が提案されていることから，CMA-ES よりも多峰性関数に向いた近似解法であると言える．

しかし，実数値 GA は次章に述べるような初期収束を明示的に防ぐ工夫はなされていないために，大域的最適解の発見が困難になる場合がある．本論文では，より広い問題クラスで有効な進化計算の開発のため，実数値 GA の初期収束を回避する方法を構築し，同時に探索効率の改善を行う．

*3 すべての PSO や EDA が変数間依存性に対処しているわけではない

3. 初 期 収 束

本章では，実数値 GA が初期収束を起こしやすい局面と発生するメカニズム，および初期収束を防ぐために提案されている工夫について概説する．

3·1 初期収束の発生する局面

実数値 GA において，初期収束は大きく分けて次の二つの景観を有する関数の最適化を行うときに頻繁に観察されることが知られている．

§1 稜構造，k-tablet 構造

稜構造 [Oyman 00a, Oyman 00b] とは，悪スケールの一種であり，ある 1 次元方向のスケーリングが他の次元と大きく異なり評価値に与える影響が鈍感であり，景観が尾根のような構造をなすものを指す．k-tablet 構造 [佐久間 04] とは，稜構造を一般化したものであり，探索空間中のある k 次元の部分空間とその補空間において評価関数値への影響が大きく異なる景観を指す．

稜構造を有する関数を実数値 GA によって最適化する場合，まず評価関数に与える影響が大きい $n-1$ 次元について最適化される．そのため，個体集団は 1 次元の尾根にそって分布する．その後，個体集団は評価値に鈍感な 1 次元の尾根にそって有望な方向に進んで行く．この集団移動の際に初期収束を起こす．k-tablet 構造に関しても同様である．

稜構造や k-tablet 構造は，最適化問題を定式化する際に，コスト関数に鈍感な，もしくは無関係な設計変数が混入する場合に発生する．また，変数毎の物理的な次元，もしくはスケールの違い (例えばメートルとミリメートル) によっても発生する．さらに，設計変数の冗長性や強い対称性は関数景観上に同じ評価値を持つ曲線を作り出し，稜構造を作り出す原因となる．

§2 多峰性

多峰性とは，探索空間中に局所的最適解が複数存在する景観を指す．多峰性には大別して，大谷構造 (big valley structure) と大域的多峰 (globally multimodal) [池田 02a] がある．大谷構造とは，探索空間中に局所的最適解が多数存在するが，巨視的には大きな谷が一つしか存在しない景観を指す．大域的多峰とは，巨視的に大きな谷が複数存在する景観を指す．本論文で議論する多峰性は，大谷構造であることを想定する*4．

*4 大域的多峰な関数に対しては ISM[池田 02b] のように大谷構造毎に探索を行うことが有効とされているが，各大谷構造が稜構造や多峰性などの関数景観を有すると探索が困難になる．大域的多峰な関数を最適化するためには，まず，大谷構造での初期収束に対処することが必要であるから，本論文では大谷構造を想定した．

実数値 GA は多峰性関数に対して有効とされるが，初期化領域の形状によって探索性能が大きく影響を受けることが指摘されている [Tsutsui 00, 染谷 01]．特に初期化領域内に大域的最適解が存在しないような場合，個体集団は有望な領域に向かって移動している間に多様性を失い，局所的最適解に収束してしまう．通常，大域的最適解の位置は不明であるため，大域的最適解を必ず含むように初期化領域をもうけることは困難である．特に，実数集合全体が定義域となる問題では必然的に探索空間の一部を初期化領域として設定することになる．

実問題において，稜構造や多峰性はしばしば現れる関数景観であり，佐久間ら [Sakuma 05] はレンズ系設計問題においてこのような関数景観が存在し，初期収束を起こしやすいと指摘している．

3·2 初期収束の発生原因

有望領域は現在の集団が分布している領域の外側に存在する場合を考える．統計量の遺伝を満たす交叉を用いた場合，子個体は親個体と同じ領域に生成される．この中で生存選択される子個体は有望な領域に偏っており，その中心は親個体よりも有望な領域に移動しているが，広がりは親個体のそれよりも必然的に小さくなる．その子個体と親個体が世代交代するため集団分布が小さくなりやすい．生存選択によって入れ替えられる個体は集団の一部であるから，集団サイズを大きくとり集団サイズに対する入れ替えられる個体の割合を小さくすることで集団の縮小を緩和することができる．しかし，一般に，評価回数は集団サイズに比例するため，集団サイズは抑制することが望ましい．

稜構造を有する関数を最適化する際，集団は比較的長い重心移動を必要とするため最適解を発見する以前に初期収束を起こしやすい．また，多峰性関数の場合，単峰性関数のように有望領域に近い個体が必ずしも選択されず，いくつかの谷にまたがって選択されるため重心移動が遅く，重心移動の間に初期収束を起こしやすい．これら二つの関数景観は重心移動を必要とする典型的な例であるが，良スケールな関数においても大域的最適解から離れた位置に狭く初期化領域が与えられた場合には初期収束を起こすことを我々は確認しており，実数値 GA は集団の移動中に初期収束を起こしやすいと言える．

3·3 既 存 手 法

このような初期収束を防ぐために，様々な工夫が提案されている．以下，代表的な既存手法を紹介する．

§1 性質の異なる探索オペレータの併用

文献 [Ono 99a] では， UNDX [小野 99b] だけでは大域的探索能力が不十分であるとし，UX [Davis 91] を組み合わせることでこれを補うハイブリッド法が提案されている．UX は局所解が座標軸にそって存在する多峰性関数においては効果的であるが，回転不変性をもたない．すなわち，座標軸にそった局所的最適解の配置でなければ探索効率が低く，良い結果が得られない．また，稜構造のような景観を有する関数を想定していない．

文献 [佐久間 02] では，稜構造における実数値 GA の初期収束は交叉のサンプリングバイアス (sampling bias, [Eshelman 97]) が原因であるとし，これを緩和する外挿的交叉 EDX が提案されている．文献 [佐久間 04] では，k-tablet 構造を考慮して設計された交叉 LUNDX-m と EDX の組み合わせが稜構造関数で高い性能を発揮することを示している．しかし，適切な初期化領域が与えられない場合の多峰性関数に関しては考慮されておらず，この場合の初期収束を防ぐことはできない．

§2 探索領域についての事前知識の活用

文献 [Tsutsui 00] では探索空間を拡張し，定義域の外側に擬似的な領域を作り出すことでサンプリングバイアスを緩和する BEM および BES が提案されている．また，文献 [染谷 01] では探索空間をトーラス状に連結することでサンプリングバイアスを緩和する TSC が提案されている．いずれの方法も大域的最適解が定義域の境界付近に存在する場合に，大域的最適解の発見確率が向上することが示されている．

しかし，この方法は境界情報を利用するものであるから，稜構造において見られる初期収束には効果がなく，定義域が矩形で表現されるような問題にしか利用できない．そのため，定義域が矩形でないか不明，もしくは実空間全体が定義域となるような問題に適用することはできない．

§3 多様性維持に優れた世代交代モデルの利用

文献 [Takahashi 00] は多様性に優れた世代交代モデルとして DDA を提案している．DDA は個体間のユークリッド距離を考慮し，生成した子個体のうち最良評価値を持つ個体と最も近い親個体を比較して評価値の良いほうを集団にもどす生存選択方法を採用する．この方法は世代交代による選択圧を緩和することで，多峰性関数において初期収束回避を狙ったものである．

しかし，ユークリッド距離を利用しており集団分布の形状を考慮しないため，悪スケールな関数の下で適切な世代交代が行われない．また，常に多様性を維持する世代交代モデルは探索効率が悪い．

§4 REX^{star} の使用

文献 [小林 09] では，REX を拡張した交叉オペレータとして REX^{star} が提案されている．これは稜構造，多峰性を有する関数のどちらにも優れた性能を発揮している．REX は複製選択によって選ばれた親個体の中心を交叉の中心として，子個体を親個体の共分散行列を保存するように生成する．一方，REX^{star} はこの中心よりも有望な方向に交叉中心をシフトする．シフトにより子個体を有望領域に生成しやすくなり，同時に交叉中心を座標軸にそった矩形領域に一様ランダムにシフトするため，結果

的に子個体の生成領域を広げることとなり，多様性の増大を引き起こすことが可能である．

しかし，シフトの大きさを定めるステップサイズパラメータの適切な値は，問題への依存性が強く，これを事前に与えることは困難である．また，矩形領域に広げるため座標系に依存し，変数間に依存性のある問題で探索性能が悪化する．

3·4 問題点の整理と提案手法の設計方針

3·3 節に挙げた既存手法は，いずれも特定の問題領域に限定して効果的な方法であるため，3·1 節で挙げた二つの状況下で有効に働き，悪スケール性や変数間依存性のある問題で一般的に有効な手法ではない．

統計量の遺伝に従う交叉は集団が大域的最適解を十分に覆っている状況下では効率的に探索領域の絞り込みを行うが，集団の外側に大域的最適解が存在する状況を想定していない．そのため，集団の外側に生成される子個体の数が少なく，稜構造や多峰性の関数の下で 3·2 節のように初期収束が発生する．3·1 節で述べたように，大域的最適解を十分に覆えない状況は頻繁に現れるため，統計量の遺伝を満たすだけでは不十分であると言える．

本論文では，有望領域が現在の集団分布の外側に存在するときに優れた子個体を生成しやすいように，適応的に子個体生成領域を変更する交叉オペレータを提案する．これを実現する一つの方法として，集団の移動中に多様性を維持および拡大させる方法が考えられる．また別の方法として，集団の移動を加速させることで集団が収束してしまう前に望ましい領域に移動させる方法が考えられる．本論文では，まず前者の方法として，4 章で交叉拡張率を適応的に調整することで集団の多様性を間接的に制御する方法を提案する．次に後者の方法として，5 章で交叉の中心を有望領域にシフトすることで重心移動の高速化法を導入する．6 章ではこの二つの方法を REX に組み込んだ新しい交叉 AREX を提案する．

4. 拡張率適応

既存の実数値交叉は，子個体生成領域の広がりを決定するパラメータを少なくとも一つは持つ．例えば REX では α がこれにあたり，このようなパラメータは交叉の拡張率と呼ばれる．通常，拡張率は統計量の遺伝を満たすように設計されるが，3·2 節で述べたように移動中に集団が初期収束を起こしやすい．拡張率を大きくして子個体を親個体よりも広く生成した場合，生存選択される子個体は広く分布する．そのため集団の広がりを維持，拡大することが予想されるが，2·1 節で述べたように，探索効率の悪化を招く．

本章では，拡張率を適応的に制御することで探索効率を犠牲にすることなく初期収束を回避する枠組みを提案する．

4·1 拡張率適応の枠組み

交叉の中心を $\boldsymbol{m}$ とし，交叉によって生成された個体のうち評価値上位 μ_α 個体の中心を $\langle \boldsymbol{x} \rangle_{\mu_\alpha}$ とする．このとき $\langle \boldsymbol{x} \rangle_{\mu_\alpha} - \boldsymbol{m}$ を *crossover descent path* (以下，CDP) と呼ぶ．評価値上位 μ_α 個の子個体が交叉の中心からある方向に偏っている場合，有望な領域は現在の集団分布の外側にあると考えられる．このとき，$\langle \boldsymbol{x} \rangle_{\mu_\alpha}$ は $\boldsymbol{m}$ から離れており，比較的長い CDP となる．逆に，評価値上位 μ_α 個の子個体が交叉中心付近に偏っている場合，現在の集団分布は有望領域をとらえていると考えられる．このとき比較的短い CDP となる．そこで，CDP の長さを拡張率適応のための指標として考える．前者の場合は集団が移動しているので拡張率を大きく，後者の場合は移動する必要がないので拡張率を小さくする．

具体的に，距離関数を $d(\cdot,\cdot)$ としたとき，現在の CDP の長さの二乗 $L_{\mathrm{cdp}} = d^2(\langle \boldsymbol{x} \rangle_{\mu_\alpha}, \boldsymbol{m})$ がランダムな環境の下 (選択圧がかからない状況下) での距離の二乗の平均 L_{avg} よりも大きいとき，拡張率を現在よりも大きくする．逆に短いときは拡張率を小さくする．提案手法では以下のようにこれを実現する．

$$\alpha^{(g+1)} := \max\left(\alpha^{(g)}\sqrt{(1-\mathrm{c}_\alpha) + \mathrm{c}_\alpha \frac{L_{\mathrm{cdp}}}{L_{\mathrm{avg}}}},\ 1\right) \quad , \qquad (5)$$

ここで g は現在の世代番号，c_α は学習率を表す．このように拡張率を適応するメカニズムを**拡張率適応 (Adaptation of Expansion Rate, AER)** と呼ぶ．

簡単のため，$\mathrm{c}_\alpha = 1$ とし，max オペレータを無視すると，$\{\alpha^{(g+1)}\}^2 L_{\mathrm{avg}} = \{\alpha^{(g)}\}^2 L_{\mathrm{cdp}}$ の関係がある．次世代の L_{avg} は現世代の $\{\alpha^{(g+1)}/\alpha^{(g)}\}^2$ 倍となることに注意すれば，次世代の L_{avg} が現在の L_{cdp} に一致するように拡張率を更新していると見なせる．

本手法の目的は初期収束を防ぐことであるから $\max(\cdot,1)$ によって $\alpha \geq 1$ としており，親個体の分布よりも狭い範囲に子個体が生成されることを防いでいる．この工夫は多峰性関数で効果があることを予備実験において確認している．

4·2 距離関数

どのような距離関数を用いて L_{cdp} および L_{avg} を評価するか，という問題は AER を設計する上で重要な問題である．距離関数を設計する上で考えなくてはならないことは，以下の二点である．

計算コスト 関数評価の計算コストが低い場合，実数値 GA における計算コストのボトルネックは交叉オペレータである．REX は各子個体の生成に $\mathcal{O}(n\mu)$ の乗除算を必要とする．式 (5) は L_{cdp} および L_{avg} が与えたとき容易に計算可能であるが，L_{cdp} および L_{avg} の計算コストが高ければ新たなボトルネックとなりかねない．そこで，これらが交叉にかかる乗除算回数以下で評価できることが望ましい．

不変性 AER は実数値交叉の拡張率のみを変化させるため，交叉の持つスケール不変性や回転不変性に影響を与えない．しかし，AER のアルゴリズムが不変性をもたなければアルゴリズム全体の不変性に影響を及ぼし，悪スケールな関数や変数間依存のある関数において非効率な探索を招く恐れがある．このことから，AER がスケール変換や回転変換に対して不変であるように距離関数を設計することが望ましい．

ユークリッド距離 (Euclidean distance) を用いた場合，計算コストの面では効率的だがスケール不変性を持たない．子個体分布の共分散を考慮したマハラノビス距離 (Mahalanobis distance) を用いた場合，スケール不変性を持つが，ナイーブにこれを計算すると計算コストが高く，$\mathcal{O}(n^3)$ の乗除算回数を必要とする．本論文ではユークリッド距離を用いた拡張率適応 **AER(E)** と，マハラノビス距離を用いた拡張率適応 **AER(M)** を提案する．また，REX とともに用いる場合の AER(M) の効率的な ($\mathcal{O}(n)$) 計算方法を示す．

まず，L_{avg} の計算方法を説明する．今，$X_1,\ldots,X_{\mu_\alpha}$ をそれぞれ交叉によって生成される子個体と同一分布に独立に従う確率変数であるとする．ランダムな評価値が与えられる関数の下では，生成された子個体のうち評価値上位 μ_α 個体は子個体生成分布と同一の分布に従っていると見なせるので，$L_{\mathrm{avg}} = \mathrm{E}[d^2((1/\mu_\alpha)\sum_{i=1}^{\mu_\alpha} X_i, \boldsymbol{m})]$ である．交叉として REX を想定すると，交叉の中心 $\boldsymbol{m}$ は親個体の中心 $\langle \boldsymbol{y} \rangle$ であり，各個体は式 (3) のように書けるので，以下のようになる．

$$L_{\mathrm{avg}} = \int \cdots \int d^2(\langle \boldsymbol{y} \rangle + \frac{\alpha}{\mu_\alpha}\sum_{i=1}^{\mu_\alpha}\sum_{j=1}^{\mu}\epsilon_{i,j}(\boldsymbol{y}_j - \langle \boldsymbol{y} \rangle), \langle \boldsymbol{y} \rangle) \\ q(\epsilon_{1,1})\cdots q(\epsilon_{\mu_\alpha,\mu})d\epsilon_{1,1}\cdots d\epsilon_{\mu_\alpha,\mu} \ , \quad (6)$$

ここで，$q(\cdot)$ は ϵ の従う確率密度関数である．後に見るように，多くの場合 L_{avg} は交叉オペレータと親個体，距離関数が決まれば解析的に求まり，積分計算を数値的に行う必要はない．

§1 AER(E)

距離関数としてユークリッド距離を用いる場合，L_{cdp} は次のようになる．

$$L_{\mathrm{cdp}} = d^2(\langle \boldsymbol{x} \rangle_{\mu_\alpha}, \boldsymbol{m}) = \|\langle \boldsymbol{x} \rangle_{\mu_\alpha} - \boldsymbol{m}\|^2 \ ,$$

ここで，$\|\cdot\|$ はユークリッドノルムを表す．

REX とともに AER(E) を用いる場合，L_{cdp} および L_{avg} は次のようになる．

$$L_{\mathrm{cdp}} = \|\langle \boldsymbol{x} \rangle_{\mu_\alpha} - \langle \boldsymbol{y} \rangle\|^2,$$

$$L_{\mathrm{avg}} = \alpha^2\sigma^2(\sum_{j=1}^{\mu}\|\boldsymbol{y}_j - \langle \boldsymbol{y} \rangle\|^2)/\mu_\alpha \ .$$

第二式は，式 (6) の距離関数としてユークリッド距離を代入し，積分を行うことで導かれる．

AER(E) において，L_{cdp} は $\mathcal{O}(n)$，L_{avg} は $\mathcal{O}(\mu n)$ の乗除算回数で計算できるため，計算コストの面ではリーズナブルであるが，スケール不変性を持たない[*5]．

§2 AER(M)

距離関数として，子個体生成分布についてのマハラノビス距離を用いる場合，L_{cdp} は次のようになる．

$$\begin{aligned} L_{\mathrm{cdp}} &= d^2(\langle \boldsymbol{x} \rangle_{\mu_\alpha}, \boldsymbol{m}) \\ &= (\langle \boldsymbol{x} \rangle_{\mu_\alpha} - \boldsymbol{m})^{\mathrm{T}}\boldsymbol{C}^{+}(\langle \boldsymbol{x} \rangle_{\mu_\alpha} - \boldsymbol{m}) \ , \end{aligned} \quad (7)$$

ここで，$\boldsymbol{C} = \mathrm{Cov}(\boldsymbol{x})$ は子個体生成分布の共分散行列を表し，$\boldsymbol{C}^{+}$ は $\boldsymbol{C}$ の Moore-Penrose 逆行列 [Harville 08] を表す[*6]．

AER(M) は親個体の集団分布を考慮するため，AER(E) よりも適切に重心移動を推定できると予想されるが，計算量の面で欠点がある．AER(E) が $\mathcal{O}(n)$ の乗除算回数で計算可能であるのに対し，AER(M) は $\mathcal{O}(n^3)$ の乗除算回数を必要とする．しかし，幸いなことに，REX (ただし $\mu \leq n+1$) とともに AER(M) を用いる場合には，この計算は $\mathcal{O}(n)$ で計算可能となる．この場合 L_{cdp} は以下のように計算できる．

$$\begin{aligned} L_{\mathrm{cdp}} &= (\langle \boldsymbol{x} \rangle_{\mu_\alpha} - \langle \boldsymbol{y} \rangle)^{\mathrm{T}}\boldsymbol{C}^{+}(\langle \boldsymbol{x} \rangle_{\mu_\alpha} - \langle \boldsymbol{y} \rangle) \\ &= \alpha^2(\mu-1)(\sum_{j=1}^{\mu}\langle \epsilon_j \rangle_{\mu_\alpha}^2 - \frac{1}{\mu}(\sum_{j=1}^{\mu}\langle \epsilon_j \rangle_{\mu_\alpha})^2) \ , \end{aligned} \quad (8)$$

ここで，添字 $i:\lambda$ を λ 個の子個体のうち評価値上位 i 番目の個体の添字を表すとすると $\langle \epsilon_j \rangle_{\mu_\alpha} = \sum_{i=1}^{\mu_\alpha}\epsilon_{i:\lambda,j}/\mu_\alpha$ である．証明は 付録 A を参照されたい．また，AER(E) と同様にして以下を得る．

$$L_{\mathrm{avg}} = \alpha^2\sigma^2(\mu-1)^2/\mu_\alpha \ .$$

REX とともに用いる場合，L_{cdp} は $\mathcal{O}(n)$ の乗除算回数で計算できる．また，L_{avg} は初めに一度計算すればよく，その計算コストも $\mathcal{O}(1)$ である．このため，AER(M) は計算コストの面でリーズナブルである．また，L_{cdp} と L_{avg} がどちらも座標に依存していないことからわかるように，AER(M) は回転不変性，スケール不変性を持つ．

5. 交叉中心降下

前章で示した拡張率適応は従来探索が困難であった問題において初期収束を回避するための方法である．本章

*5 交叉 REX の線形変換に対する不変性から，親 $\boldsymbol{y}_1,\ldots,\boldsymbol{y}_\mu$ から生成される子 $\boldsymbol{x}$ に対して，任意の線形変換 $\boldsymbol{T}$ について親 $\boldsymbol{T}\boldsymbol{y}_1,\ldots,\boldsymbol{T}\boldsymbol{y}_\mu$ から生成される子は $\boldsymbol{T}\boldsymbol{x}$ と書ける．このとき，$\boldsymbol{T}$ がユニタリ変換であれば変換の前後で $L_{\mathrm{cdp}}/L_{\mathrm{avg}}$ の値が変化せず，式 (5) の値が変わらないことから回転不変性が確認される．スケール変換に対しては一般に $L_{\mathrm{cdp}}/L_{\mathrm{avg}}$ の値が変わり，式 (5) の出力が変わることから，スケール不変性を持たないことが確認される．

*6 通常の逆行列のかわりに Moore-Penrose 逆行列を用いたのは $\boldsymbol{C}$ が正則でない場合も扱えるようにするためであり，正則であれば逆行列と等価であることに注意されたい．

ではこれに加え，子個体生成領域を有望な領域にシフトすることで重心移動を加速することで，初期収束を防ぐと同時に探索効率を向上させる方法を提案する．

5·1 REX^{star} における交叉中心シフトの考察

交叉 REX^{star} は交叉 REX における子個体生成分布の中心を推定された有望領域にシフトする．交叉中心をシフトする際，推定された降下方向 (大域的降下方向) の各要素に対して正の一様乱数を掛けたベクトルを，REX によって生成された各個体に対して加える．このとき，REX^{star} は交叉の中心を有望領域にシフトすると同時に子個体生成領域を矩形に広げていると解釈できる．

文献 [小林 09] では，降下方向の直線上に交叉中心をシフトする REX$_{line}$ と REX^{star} および REX が実験により比較されており，REX$_{line}$ は REX よりも，また多くの場合に REX^{star} は REX$_{line}$ よりも探索効率が高いことが示されている．このことから，交叉中心のシフトの有効性と，多くの場合に子個体生成領域を拡大することで探索性能の向上が確認される．しかし，REX^{star} は矩形領域に子個体をシフトさせることで REX の持つ回転不変性を壊すことになり，変数間依存性のある関数を最適化する際に著しく探索効率が悪化する．

REX と比較した REX$_{line}$ の成功から，交叉中心のシフトを導入することで初期収束回避，および探索効率向上が期待できる．また，REX^{star} と REX$_{line}$ の比較から，交叉中心のシフトに拡張率適応を組み合わせることで相乗的に働くことが予想される．

5·2 交叉中心降下

既存の多くの交叉は，複製選択によって選択された親個体の平均ベクトルを交叉の中心として子個体を生成する．子個体生成領域を有望領域にシフトする方法として，親個体の評価値ランキングに基づく加重平均を交叉中心として子個体を生成する方法が考えられる．REX では，式 (3) のように親個体の平均ベクトル $\langle \boldsymbol{y} \rangle$ を中心に子個体を生成するが，提案手法ではこれを以下のように変更する．

$$\boldsymbol{x}_i = \boldsymbol{m} + \alpha \sum_{j=1}^{\mu} \epsilon_{i,j} \left(\boldsymbol{y}_j - \langle \boldsymbol{y} \rangle \right), \quad \boldsymbol{m} = \sum_{j=1}^{\mu} w_j \boldsymbol{y}_{j:\mu} \ ,$$

ここで，添字 $i:\mu$ は親 μ 個体のうち評価値上位 i 番目の個体の添字をあらわし，また $w_j = 2(\mu+1-j)/(\mu(\mu+1))$ は線形の重みで $\sum_{j=1}^{\mu} w_j = 1$ である．このように，交叉の中心を有望領域にシフトする戦略を**交叉中心降下**と呼ぶことにする．

評価値ランキングに基づく加重平均をとることで交叉中心を降下させる方法は，交叉の持つスケール不変性や回転不変性に影響を与えない．また，拡張率適応との相性も良い．拡張率適応は交叉中心から各個体への差ベクトルを利用するが，交叉中心降下によってこれらは変化しない．そのため拡張率適応はそのまま適用可能であり，REX における AER(M) の効率的計算も利用できる．

表 1 パラメータの推奨値

交叉に参加する親数	$\mu = n+1$
生成子個体数	$\lambda = 4n (\approx 4\mu)$
REX に用いる乱数	$\epsilon \sim \mathcal{N}(0, \sigma^2)$
乱数の分散	$\sigma^2 = 1/(\mu-1)$
初期拡張率	$\alpha^{(0)} = 1$
学習率	$c_\alpha = 1/5n$
利用する子個体数	$\mu_\alpha = \mu$

6. AREX

4 章で提案した AER(M) と 5 章で提案した交叉中心降下を REX に組み込んだ新しい交叉を **AREX (adaptive real-coded ensemble crossover)** として提案する．

6·1 AREX の 特 徴

AREX は REX と同様に回転不変性とスケール不変性を持つため，変数間依存性や悪スケール性のある問題に対しても有効であると考えられる．AREX は拡張率適応のために毎世代一度 $\mathcal{O}(n)$ の計算コストがかかるが，AREX と REX はどちらも一個体を生成するための計算コストが $\mathcal{O}(n\mu)$ であり，λ 個の個体生成と評価を並列化したとしても一世代にかかる追加コストは十分小さく，計算コストは同程度である．

集団の重心がほとんど移動しないとき，AREX の拡張率は $\alpha \approx 1$ となり，また，交叉中心は加重平均をとる場合と標本平均をとる場合とでほとんど変わらない．そのため，統計量の遺伝に従う REX と同様の振る舞いを示す．一方で，集団重心が移動しているとき，AREX は統計量の遺伝を積極的に破り，重心移動を加速し，子個体生成領域を広げる．

6·2 パラメータの推奨値

提案手法において，二つのパラメータ c_α と μ_α を導入した．これらのパラメータに限らず，実数値 GA に内在するパラメータは対象とする問題によってチューニングすることで高い性能を発揮し得る．しかし，これは使用者の観点からすれば負担であり，パラメータの推奨値を与えることは重要である．複数のベンチマーク問題を用いた予備実験の結果から，推奨値として 表 1 を与える．

交叉に参加する親数は AER(M) を効率的に計算できる最大の値であり，これは従来 [小林 09] で利用されている値と等しい．生成子個体数は探索過程における選択圧と探索効率を決定するパラメータであり，予備実験により決定した．σ は不偏分散の意味で統計量の遺伝を満たすパラメータ設定であり，$\alpha^{(0)}$ はこれに従い 1 とした．AER で利用する子個体の選択数は JGG の下で利用する

表 2 AER(E) と AER(M)，および拡張率適応を行わない REX/JGG における，最適集団サイズ (右) とその際の探索成功試行の平均評価回数 (左).

Dim.	AER(E)	AER(M)	REX	AER(E)	AER(M)	REX
	f_1: Sphere function, $[-5,5]^n$			f_2: Offset Sphere function, $[1,5]^n$		
$n=20$	$2.67\times10^4, 5n$	$2.83\times10^4, 5n$	$3.33\times10^4, 10n$	$3.39\times10^4, 5n$	$3.36\times10^4, 5n$	$4.19\times10^4, 10n$
$n=40$	$1.08\times10^5, 10n$	$1.06\times10^5, 10n$	$9.85\times10^4, 10n$	$1.47\times10^5, 5n$	$1.42\times10^5, 5n$	$1.52\times10^5, 15n$
$n=80$	$3.58\times10^5, 10n$	$3.61\times10^5, 10n$	$3.23\times10^5, 10n$	$1.04\times10^6, 10n$	$4.93\times10^5, 10n$	$4.41\times10^5, 15n$
	f_3: Scaled Sphere function, $[-5,5]^n$			f_4: Scaled rotated Sphere function, $[-5,5]^n$		
$n=20$	$2.76\times10^4, 5n$	$2.83\times10^4, 5n$	$3.33\times10^4, 10n$	$2.76\times10^4, 5n$	$2.83\times10^4, 5n$	$3.33\times10^4, 10n$
$n=40$	$1.08\times10^5, 10n$	$1.06\times10^5, 10n$	$9.85\times10^4, 10n$	$1.08\times10^5, 10n$	$1.06\times10^5, 10n$	$9.85\times10^4, 10n$
$n=80$	$3.61\times10^5, 10n$	$3.61\times10^5, 10n$	$3.23\times10^5, 10n$	$3.61\times10^5, 10n$	$3.61\times10^5, 10n$	$3.23\times10^5, 10n$

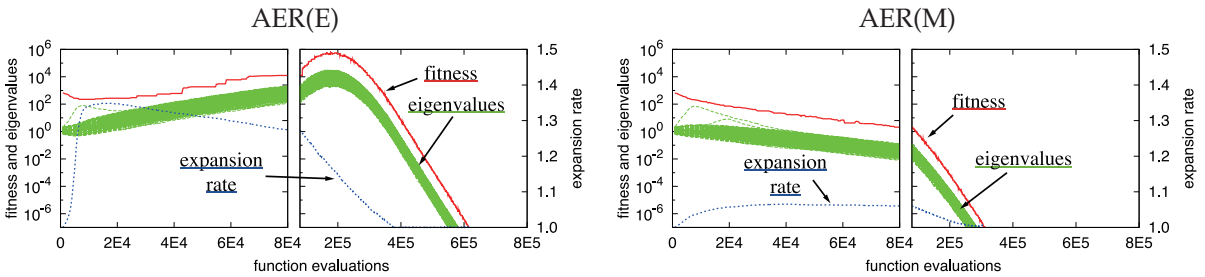

図 1 80 次元 f_2 (Offset Sphere) 関数における，AER(E) (左) および AER(M) (右) を用いた REX/JGG の典型的な一試行の結果．図中の fitness (赤) は評価値，eigenvalues (黄緑) は集団の共分散行列の固有値を表し，expansion rate (青) は拡張率 を表す．探索序盤を強調するために，横軸のスケールは 8.0×10^4 を境に異なり，また，評価値と固有値は左軸，拡張率は右軸に対応することに注意されたい．

場合，$\mu_\alpha=\mu$ とするのが最も自然である．学習率については予備実験により決定した．

7. 評 価 実 験

本章では，ベンチマーク関数を用いた実験により提案手法の性能を確認する．実験 1 では AER(E) と AER(M)，および拡張率適応を行わない REX/JGG におけるスケール不変性や回転不変性などの基本的な性質を比較，確認する．実験 2 では拡張率適応の有効性を確認するため，稜構造を有する関数や多峰性を有する関数の下で既存手法との比較を行う．実験 3 ではさらに交叉中心降下を加えることによる相乗効果を確認する．

7·1 共 通 設 定

以下で用いるベンチマーク関数は次元数を自由に変えることができる．本論文では次元数 $n=20,40,80$ とした．

集団サイズ $N_{\rm pop}$ を除いたすべてのパラメータは，表 1 で示した推奨値を用いる．問題の景観により，必要な集団サイズは大きく異なるため，$N_{\rm pop}=5n, 10n, 15n, 20n, 25n, 30n, 35n, 40n, 45n, 50n$ のすべての設定において実験を行う．初期集団は与えられた初期化領域内に集団サイズと同数だけ一様ランダムに生成する．

すべての実験を擬似乱数の種を変えて 50 試行実施する．各試行は評価値 $f_{\rm stop}=10^{-7}$ 以下の値を獲得したとき探索成功と見なして探索を終了する．探索成功と見なされる前に GA の世代数が $n*10^4$ を超えた場合は探索失敗と見なし，探索を終了する．

以下では，成功確率が 96% 以上 (50 試行中 48 試行以上探索成功) となる集団サイズのうち，成功試行時の探索終了までに費やす目的関数評価の平均回数が最小となる集団サイズを**最適集団サイズ**と呼び，その際の探索成功試行の平均評価回数をもって評価を行う*7*8．成功確率の異なる手法間の探索効率を比較するため，最適集団サイズにおける探索成功試行の平均評価回数を成功確率で割ったものを **performance** と呼ぶことにする．

7·2 実験 1: 拡張率適応の基本性能評価

二つの拡張率適応メカニズム AER(E) と AER(M) の基本性能を比較，確認する．

§1 評価関数

以下のような評価関数を用いる．

$$f(\boldsymbol{x})=\boldsymbol{x}^{\rm T}\boldsymbol{A}\boldsymbol{x}\ ,$$

ここで，$\boldsymbol{A}$ は正定値対称行列である．$\boldsymbol{A}$ および初期化領域を変更することで以下の 4 つの関数を考え，評価関数として利用する．

f_1 (Sphere) $\boldsymbol{A}=\boldsymbol{I}$,

初期集団は $[-5,5]^n$ に一様ランダム．

*7 以下で示す結果において，評価回数の標準偏差は平均評価回数の 5% 程度，大きくとも (後に示す f_1 関数の下で) 10% 程度であり，手法の比較を行う上で十分小さいと見なせるため省略した．

*8 提案手法は既存手法と同程度の計算コストであるから，実際にかかる計算時間の比は評価回数の比と同程度であることに注意されたい．

表 3 評価関数の定義と特徴.

関数名	関数定義	初期化領域	特徴
f_5: Cigar	$f_5 = x_1^2 + \sum_{i=2}^{n}(1000 \cdot x_i)^2$	$[1,5]^n$	直線の稜構造
f_6: k-tablet ($k = n/4$)	$f_6 = \sum_{i=1}^{k} x_i^2 + \sum_{i=k+1}^{n}(100 \cdot x_i)^2$	$[1,5]^n$	k-tablet 構造
f_7: Rosenbrock (star)	$f_7 = \sum_{i=2}^{n} 100(x_i^2 - x_1)^2 + (x_i - 1)^2$	$[-2,2]^n$	曲線の稜構造
f_8: Rosenbrock (chain)	$f_8 = \sum_{i=1}^{n-1} 100(x_i^2 - x_{i+1})^2 + (x_i - 1)^2$	$[-2,2]^n$	曲線の稜構造
f_9: Bohachevsky	$f_9 = \sum_{i=1}^{n-1}(x_i^2 + 2x_{i+1}^2 - 0.3\cos(3\pi x_i) - 0.4\cos(4\pi x_{i+1}) + 0.7)$	$[1,15]^n$	弱い多峰性
f_{10}: Schaffer	$f_{10} = \sum_{i=1}^{n-1}(x_i^2 + x_{i+1}^2)^{0.25} \cdot [\sin^2(50 \cdot (x_i^2 + x_{i+1}^2)^{0.1}) + 1.0]$	$[10,100]^n$	強い多峰性
f_{11}: Rastrigin	$f_{11} = 10n + \sum_{i=1}^{n} x_i^2 - 10\cos(2\pi x_i)$	$[1,5]^n$	強い多峰性

f_2 **(Offset Sphere)** $\boldsymbol{A} = \boldsymbol{I}$,
初期集団は $[1,5]^n$ に一様ランダム.

f_3 **(Scaled Sphere)** $\boldsymbol{A} = \boldsymbol{D}^2 = \mathrm{diag}(1^2, \ldots, n^2)$,
初期集団は $[-5,5]^n$ に一様ランダムに生成した個体 $\boldsymbol{x}$ に対して $\boldsymbol{D}^{-1}\boldsymbol{x}$.

f_4 **(Scaled rotated Sphere)** $\boldsymbol{A} = \boldsymbol{H}^{\mathrm{T}}\boldsymbol{D}^2\boldsymbol{H}$,
初期集団は $[-5,5]^n$ に一様ランダムに生成した個体 $\boldsymbol{x}$ に対して $\boldsymbol{H}^{\mathrm{T}}\boldsymbol{D}^{-1}\boldsymbol{x}$.

ここで $\boldsymbol{H}$ は対応する次元数の Helmert 行列 *9 を表す. いずれの関数も $\boldsymbol{x} = \boldsymbol{0}$ で最小値 $f(\boldsymbol{x}) = 0$ をとる.

関数 f_1 はよく知られた Sphere 関数である. 関数 f_2 は f_1 の初期化領域をシフトすることで大域的最適解を含まないようにしたものである. 関数 f_3 は f_1 を座標毎に異なるスケーリングをすることで悪スケールにした関数である. 関数 f_4 は f_1 の座標軸を回転させてから悪スケール化させたものである. f_1 と f_2 における探索性能を比較することで初期化領域の取り方による探索性能の変化, f_1 と f_3 における探索性能を比較することで悪スケール性に対する性能, f_3 と f_4 における探索性能を比較することで変数間依存性に対する性能 (座標系の取り方に対する不変性) を確認する.

§2 結果と考察

AER(E) と AER(M), および拡張率適応を行わない REX/JGG の実験結果を表 2 に示す.

交叉 REX は回転不変性とスケール不変性を持ち, また JGG は評価値のランキング以外の情報を利用しないため, REX/JGG は回転変換, およびスケール変換に対して不変であり, f_1, f_3, f_4 において全く同じ結果を示す. AER(E) と AER(M) も回転不変性を持つため, f_3 と f_4 の結果は一致する.

次に, AER(E) はスケール不変性を持たないにも関わらず, f_1 と f_3 の結果は AER(E) と AER(M) ともにほとんど変わらないことが観察される. f_3 のように最適解が初期化領域の中心にある場合, 重心は移動しないため, どちらの拡張率適応を用いても探索過程において $\alpha \approx 1$ となる. このとき, 拡張率適応を用いない REX/JGG と変わらないため, スケール不変性を持たないことの悪影響は観察されない.

しかし, スケール不変性の有無は f_2 の結果に差をもたらす. 表 2 からわかるように, 80 次元では大きな差が生じる. f_1 での結果と比較して, AER(M) では初期化領域の違いによって生じる評価回数の増加が少ないのに対し, AER(E) では明らかに多くの評価回数を必要とする. この原因を 図 1 に示す. 探索の序盤に集団が最適解の存在する $\boldsymbol{x} = \boldsymbol{0}$ に向かって移動する際, 移動方向 (初期集団の重心が $\boldsymbol{x} = \boldsymbol{3}$ 付近であるから, $-\boldsymbol{1}$ の方向である) に集団が広がって分布する. そのため, 集団内個体の共分散行列の最大固有値に対応する固有ベクトルはおおよそ移動方向と平行であり, その最大固有値はその他の固有値と比較して非常に大きい. AER(E) は集団分布の形状を考慮しないため, このとき CDP の長さを過度に大きく見積もり, 図 1 のように拡張率を大きくしてしまう. これに対し AER(M) では分布の形状を考慮するため適切に働いている.

提案手法と既存手法を比較する. f_1 から f_4 のように, 既存手法にとって探索が比較的容易な関数の下では拡張率を大きくする必要がほとんどなく, 提案手法は探索効率の低下を招くが, 必要な集団サイズは少ないため, 結果として評価回数に大きな差は生じない. 高次元になると既存手法が僅かに少ない評価回数で探索に成功していることは, 拡張率適応の学習率に起因する. 本実験では学習率を次元数に反比例するように設定したが, 既存手法にとって探索が容易な関数の下では学習率を高くすることで探索効率は改善される.

以上の考察より, アルゴリズムの回転不変性, スケール不変性を持つ AER(M) は AER(E) よりも良い性質をもっており, また, 4·2·2 節で示したように $\mathcal{O}(n)$ で計算できるため, AER(M) は AER(E) よりも優れていると結論付ける. また, f_1 から f_4 のようにシンプルな関数においては, 提案手法は既存手法と同程度の評価関数で探索が可能であることを確認した.

7·3 実験 2: 拡張率適応の有効性

次に, 稜構造や多峰性を有する関数の下での提案手法の有効性を確認するために, AER(M) を用いた REX/JGG (提案手法) と REX/JGG (既存手法) を比較する.

*9 Helmert 行列は, 第 1 行ベクトルが $n^{-1/2}(1, \ldots, 1)$ であり, 第 k 行ベクトルが $[k(k-1)]^{-1/2}(1, \ldots, 1, 1-k, 0, \ldots, 0)$ (係数を無視すれば, 1 列目から $k-1$ 列目までの要素が 1, k 列目が $1-k$, $k+1$ 列目以降が 0 となるベクトル) となる直交行列 ($\boldsymbol{H} \cdot \boldsymbol{H}^{\mathrm{T}} = \boldsymbol{H}^{\mathrm{T}} \cdot \boldsymbol{H} = \boldsymbol{I}$) である

表 4 実験 2，稜構造関数における結果．提案手法 (AER(M) を用いた REX/JGG) と既存手法 (REX/JGG) における，最適集団サイズ (右) とその際の探索成功試行の平均評価回数 (左) を表す．“比率” は提案手法の performance を 1 としたときの既存手法の performance を表す．

次元数	提案手法	既存手法	比率
f_5: Cigar function, $[1,5]^n$			
$n=20$	6.14×10^4, $5n$	2.23×10^5, $25n$	3.63
$n=40$	2.51×10^5, $5n$	7.49×10^5, $30n$	2.98
$n=80$	9.42×10^5, $10n$	2.42×10^6, $35n$	2.57
f_6: k-tablet function, $[1,5]^n$			
$n=20$	5.33×10^4, $5n$	1.74×10^5, $25n$	3.26
$n=40$	2.13×10^5, $10n$	6.11×10^5, $30n$	2.87
$n=80$	7.64×10^5, $10n$	2.24×10^6, $35n$	2.57
f_7: Rosenbrock (star) function, $[-2,2]^n$			
$n=20$	9.96×10^4, $10n$	2.73×10^5, $30n$	2.74
$n=40$	3.25×10^5, $10n$	8.08×10^5, $35n$	2.49
$n=80$	1.11×10^6, $10n$	2.30×10^6, $35n$	2.07
f_8: Rosenbrock (chain) function, $[-2,2]^n$			
$n=20$	1.39×10^5, $5n$	2.12×10^6, $50n$	15.3
$n=40$	8.28×10^5, $5n$	(0/50)	–
$n=80$	5.87×10^6, $10n$	(0/50)	–

表 5 実験 2，多峰性関数における結果．提案手法 (AER(M) を用いた REX/JGG) と既存手法 (REX/JGG) における，最適集団サイズ (右) と 探索成功試行の平均評価回数 (左) を表す．“比率” は提案手法の performance を 1 としたときの既存手法の performance を表す．† は 50 試行中 1 試行，‡ は 2 試行探索失敗したことを表す．48 試行以上成功しないものに関しては $N_{\mathrm{pop}}=50n$ での成功確率と成功試行の平均評価回数を表す．

次元数	提案手法	既存手法	比率
f_9: Bohachevsky function, $[1,15]^n$			
$n=20$	4.16×10^4, $5n$	6.39×10^4, $15n^{\ddagger}$	1.60
$n=40$	1.66×10^5, $10n$	1.85×10^5, $15n^{\ddagger}$	1.16
$n=80$	5.78×10^5, $10n$	5.33×10^5, $15n^{\ddagger}$	0.96
f_{10}: Schaffer function, $[10,100]^n$			
$n=20$	2.52×10^5, $15n^{\dagger}$	3.86×10^5, $25n$	1.50
$n=40$	9.54×10^5, $20n$	1.31×10^6, $30n^{\dagger}$	1.40
$n=80$	3.46×10^6, $25n$	4.33×10^6, $35n^{\ddagger}$	1.30
f_{11}: Rastrigin function, $[1,5]^n$			
$n=20$	1.58×10^5, $20n$	3.45×10^5 (21/50)	–
$n=40$	4.01×10^5, $20n^{\ddagger}$	8.90×10^5 (1/50)	–
$n=80$	1.57×10^6, $20n$	(0/50)	–

§1 稜構造関数

評価関数として，表 3 に示した f_5，f_6，f_7，f_8 関数を用いる．

実験結果を 表 4 に示す．いずれの稜構造関数の下でも提案手法が既存手法と比較して良好な性能を示すことがわかる．既存手法では探索過程において集団の多様性を保つことが困難であり，集団サイズを大きく必要とし，必然的に評価回数を多く費やすことになる．これに対し，提案手法は少ない集団サイズで多様性を制御することができるため，探索効率が高い．とりわけ，f_8 関数でその結果が顕著であるが，これは非常に長い曲線の稜構造を有する f_8 関数は既存手法での探索が困難であり，初期収束を起こしてしまうからである．一方，提案手法では f_1 (Sphere) 関数と同程度の集団サイズで最適解の発見に成功するため，探索効率が高い．

f_5, f_6 関数においては大域的最適解が初期化領域の外部となるが，大域的最適解を初期集団の中心に含むように初期化領域をとった場合 ($[-5,5]^n$ とした場合)，既存手法は前者の場合より少ない集団サイズでも初期収束を起こしにくく，評価回数も少なくなる．この場合でも提案手法と比較して 1.1 から 1.4 倍程度の評価回数を費やすことから，提案手法は初期化領域によらずに有効であることがわかる．

以上より，稜構造関数における提案手法の有効性が確認された．

§2 多峰性関数

評価関数として，表 3 に示した f_9，f_{10}，f_{11} 関数を用いる．いずれも大域的単峰な多峰性関数であり，$\boldsymbol{x}=\boldsymbol{0}$ で大域的最適解 0 を持つことが知られている．

実験結果を表 5 に示す．f_9，f_{10}，f_{11} 関数のように，初期化領域内に大域的最適解を含まないような多峰性関数において，提案手法は既存手法と比較して良好な性能を示すことがわかる．提案手法は拡張率の適応により，間接的に集団の分散をコントロールすることができるため，比較的少ない集団サイズで，そのため少ない評価回数で，最適解の発見に成功する．特に，f_{11} 関数において，既存手法では集団が移動中に多様性を失い最適解を発見することが困難であるが，提案手法では拡張率を増加させることで多様性を増大し，大域的最適解の発見に成功する．f_9 関数では高次元になると既存手法の方が少ない評価回数で探索成功している．f_9 関数は f_1 関数と同程度の集団サイズで最適解を発見できる比較的容易な関数であり，f_1 関数と同様に f_9 関数にとって次元数に反比例する拡張率適応の学習率は小さい．このため，提案手法は高次元で探索効率が低下しているが，学習率を大きくとることで改善する．

初期化領域の中心に大域的最適解が存在するよう初期化領域を定めた場合 (f_9, f_{10}, f_{11} についてそれぞれ $[-15,15]^n$, $[-100,100]^n$, $[-5,5]^n$)，既存手法であっても良好な性能を示す．既存手法は提案手法と比較して同程度か，収束が早いため僅かに少ない評価回数で探索に成功する．しかし，表 5 に示したように，既存手法は初期化領域の取り方が変わった場合に集団サイズを多く必要とし，評価回数が増大する．これに対し，提案手法では同程度の集団サイズで探索が可能であり，初期化領域への依存性が緩和されている．

以上の結果から，多峰性関数の下での提案手法の有効性が確認された．

表 6 実験 3 の結果．AREX/JGG における最適集団サイズとその際の探索成功試行の平均評価回数．CMD，AER，REX はそれぞれ AREX/JGG の performance を 1 としたときの，REX with 交叉中心降下/JGG，REX with AER(M)/JGG，REX/JGG の performance を表す．† は 50 試行中 1 試行探索失敗したことを表す．f_3 と f_4 はいずれの手法でも f_1 と等しい結果となるため省略した．

f	n	AREX	CMD	AER	REX
f_1	20	$\mathbf{1.92 \times 10^4}, 5n$	1.60	1.48	1.73
	40	$\mathbf{8.12 \times 10^4}, 10n$	1.11	1.31	1.21
	80	$\mathbf{2.61 \times 10^5}, 10n$	**1.00**	1.38	1.23
f_2	20	$\mathbf{2.32 \times 10^4}, 5n$	1.34	1.45	1.81
	40	$\mathbf{9.02 \times 10^4}, 5n$	**1.00**	1.57	1.84
	80	$3.11 \times 10^5, 10n$	**0.84**	1.59	1.42
f_5	20	$6.38 \times 10^4, 5n$	1.65	**0.96**	3.50
	40	$\mathbf{2.37 \times 10^5}, 5n$	1.54	1.06	3.16
	80	$1.05 \times 10^6, 10n$	1.02	**0.90**	2.30
f_6	20	$\mathbf{5.03 \times 10^4}, 5n$	1.78	1.06	3.46
	40	$\mathbf{1.95 \times 10^5}, 5n$	1.69	1.09	3.13
	80	$\mathbf{7.51 \times 10^5}, 10n$	1.49	1.02	2.98
f_7	20	$\mathbf{6.89 \times 10^4}, 10n$	1.35	1.45	3.96
	40	$\mathbf{2.15 \times 10^5}, 10n$	1.22	1.51	3.76
	80	$8.52 \times 10^5, 15n$	**0.96**	1.30	2.70
f_8	20	$\mathbf{1.08 \times 10^5}, 5n$	7.27	1.29	19.6
	40	$\mathbf{6.26 \times 10^5}, 5n$	18.7	1.32	-
	80	$\mathbf{4.23 \times 10^6}, 10n$	-	1.39	-
f_9	20	$4.05 \times 10^4, 10n$	**0.98**	1.03	1.64
	40	$1.20 \times 10^5, 10n$	**0.93**	1.38	1.61
	80	$3.56 \times 10^5, 10n$	**0.90**	1.62	1.56
f_{10}	20	$\mathbf{2.22 \times 10^5}, 15n$	1.01	1.16	1.74
	40	$\mathbf{6.40 \times 10^5}, 15n$	1.36	1.49	2.09
	80	$\mathbf{1.83 \times 10^6}, 15n^\dagger$	1.35	1.85	2.42
f_{11}	20	$1.84 \times 10^5, 25n$	1.79	**0.86**	-
	40	$5.15 \times 10^5, 25n$	-	**0.81**	-
	80	$\mathbf{1.52 \times 10^6}, 25n$	-	1.03	-

7·4 実験 3: 交叉中心降下の効果

交叉中心降下を導入する効果と，拡張率適応との相乗効果を確認するために f_1 から f_{11} において前節と同様の実験を行う．

実験結果を 表 6 に示す．AREX は REX と比較して，すべての関数の下で大幅に評価回数を削減している．また，拡張率適応と交叉中心降下を単独で利用した場合と比較して，多くの関数の下で AREX は高い探索効率を示していることから，二つの相乗効果が確認できる．

交叉中心降下を単体で用いた場合，REX と比較するとすべての関数で探索効率が改善している．一方，拡張率適応ほどには初期収束を回避する能力がないため，長い稜構造を有する f_8 や 多峰性の厳しい f_{11} では初期収束を起こす．拡張率適応とともに用いることで初期収束を回避する能力を持ち，また，拡張率適応の効果により小さい集団サイズでの探索が可能となり，結果として多くの関数で探索効率が改善する．

REX^{star} と比較して，提案手法は回転不変性を持つため変数間依存のある問題で探索効率が高い．例えば f_5 関数の座標系を回転させたような関数において REX^{star} は回転させていない f_5 関数での結果と比較して著しく探索効率が悪化するが，提案手法では回転変換によっては探索性能が悪化しない．このことから，提案手法は REX^{star} と比較して広い問題クラスで効果的であると言える．

8. お わ り に

本論文では，実数値 GA においてしばしば観察される初期収束のうち特に初期収束を起こしやすい関数景観として知られている稜構造と多峰性に着目し，初期収束の原因は集団が有望領域に移動する際に多様性を失いやすいことにあるとした．本論文では，これを回避する二つの方法を提案した．一つ目は，集団が移動中に交叉による子個体生成領域を広げることで集団の縮小を回避する方法であり，交叉の拡張率を適応的に調節することにより実現した．二つ目は，集団の移動を加速することで初期収束回避および探索効率改善を狙ったもので，交叉の中心を有望領域に降下させることで実現した．この二つを組み合わせた提案手法は，既存手法では最適解を発見することが困難であった稜構造関数や多峰性関数において有効であり，探索効率も向上することがベンチマーク関数を用いた実験によって明らかになった．提案手法はスケール不変性や回転不変性をもち，問題領域に関する事前知識なども必要としないため，広い問題クラスで有効である．

本論文では AREX/JGG を用いた実数値 GA におけるパラメータに推奨値を与え，集団サイズ以外はこの値を用いて良好な性能を示した．使用者の立場からすれば，パラメータが少ないことはパラメータの調整にかかる時間を大きく削減できるため，非常に重要である．一方で，適切な集団サイズの値は関数景観に依存するため，事前に適切な値を決めることは困難である．このことは，集団サイズパラメータを問題景観に応じて適応することの必要性を示唆しており，今後の課題である．

◇ 付 録 ◇

A. 式 (8) の 導 出

式 (8) を導出する．導出に先立ち重要な定理を導く．

式 (3) のように表現される個体 $\boldsymbol{x}$ について，交叉に参加する親個体の共分散行列 $\boldsymbol{C}$ に基づく交叉中心 $\boldsymbol{m}$ からの Mahalanobis 距離の二乗 $(\boldsymbol{x}-\boldsymbol{m})^{\mathrm{T}}\boldsymbol{C}^{+}(\boldsymbol{x}-\boldsymbol{m})$ は $\mathcal{O}(n)$ で計算することが可能である．これを示すのが次の定理である．

[定理 1] $\boldsymbol{y}_1, \ldots, \boldsymbol{y}_\mu \in \Re^n$ $(2 \le \mu \le n+1)$ を n 次元列ベクトルとし，

$$\langle \boldsymbol{y} \rangle = \frac{1}{\mu}\sum_{i=1}^{\mu} \boldsymbol{y}_i, \quad \boldsymbol{d}_i = \boldsymbol{y}_i - \langle \boldsymbol{y} \rangle, \quad \boldsymbol{C} = \frac{1}{\mu-1}\sum_{i=1}^{\mu} \boldsymbol{d}_i \boldsymbol{d}_i^{\mathrm{T}} ,$$

とする．今，$\boldsymbol{d}_1, \ldots, \boldsymbol{d}_{\mu-1}$ を線形独立であると仮定する．このと

き，任意の $\epsilon_1,\ldots,\epsilon_\mu \in \Re$ と $\alpha \in \Re$ について以下が成立する．

$$(\alpha\sum_{i=1}^{\mu}\epsilon_i\boldsymbol{d}_i)^{\mathrm{T}}\boldsymbol{C}^{+}(\alpha\sum_{i=1}^{\mu}\epsilon_i\boldsymbol{d}_i) = \alpha^2(\mu-1)(\sum_{i=1}^{\mu}\epsilon_i^2-\frac{1}{\mu}(\sum_{i=1}^{\mu}\epsilon_i)^2)\ , \quad \text{(A.1)}$$

ここで $\boldsymbol{C}^{+}$ は $\boldsymbol{C}$ の Moore-Penrose 逆行列を表す．

《証明》 (A.1) の左辺を展開して以下を得る．

$$(\alpha\sum_{i=1}^{\mu}\epsilon_i\boldsymbol{d}_i)^{\mathrm{T}}\boldsymbol{C}^{+}(\alpha\sum_{i=1}^{\mu}\epsilon_i\boldsymbol{d}_i) = \alpha^2\sum_{i=1}^{\mu}\sum_{j=1}^{\mu}\epsilon_i\epsilon_j\boldsymbol{d}_i^{\mathrm{T}}\boldsymbol{C}^{+}\boldsymbol{d}_j\ . \quad \text{(A.2)}$$

ここで $\mathbf{1}_{\mu-1}$ をすべての要素が 1 となる $(\mu-1)$ 次元の列ベクトルとする．また，$\boldsymbol{X}=(\boldsymbol{d}_1,\ldots,\boldsymbol{d}_{\mu-1})^{\mathrm{T}}$ とする．定義より，$\boldsymbol{d}_i$ の和 $\sum_{i=1}^{\mu}\boldsymbol{d}_i$ は 0 であるから，

$$\boldsymbol{d}_\mu = -\sum_{i=1}^{\mu-1}\boldsymbol{d}_i = -\boldsymbol{X}^{\mathrm{T}}\mathbf{1}_{\mu-1}\ . \quad \text{(A.3)}$$

また，簡単にわかるように，

$$\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X} = \sum_{i=1}^{\mu-1}\boldsymbol{d}_i\boldsymbol{d}_i^{\mathrm{T}},\quad \boldsymbol{X}^{\mathrm{T}}\mathbf{1}_{\mu-1}\mathbf{1}_{\mu-1}^{\mathrm{T}}\boldsymbol{X} = \boldsymbol{d}_\mu\boldsymbol{d}_\mu^{\mathrm{T}}$$

であるから，以下を得る．

$$\boldsymbol{C} = \frac{1}{\mu-1}\left(\boldsymbol{X}^{\mathrm{T}}\boldsymbol{X}+\boldsymbol{X}^{\mathrm{T}}\mathbf{1}_{\mu-1}\mathbf{1}_{\mu-1}^{\mathrm{T}}\boldsymbol{X}\right) = \frac{1}{\mu-1}\boldsymbol{X}^{\mathrm{T}}(\boldsymbol{I}+\boldsymbol{J})\boldsymbol{X}\ ,$$

ここで $\boldsymbol{J}$ はすべての要素が 1 となる $(\mu-1)\times(\mu-1)$ 行列であり，$\boldsymbol{J}=\mathbf{1}_{\mu-1}\mathbf{1}_{\mu-1}^{\mathrm{T}}$ である．

明らかなように，$\boldsymbol{I}+\boldsymbol{J}$ は正則であり，また仮定より $\boldsymbol{d}_1,\ldots,\boldsymbol{d}_{\mu-1}$ は線形独立であるから $\boldsymbol{X}$ は full row rank，すなわち $\mathrm{rank}(\boldsymbol{X})=\mu-1$ であるから，$\boldsymbol{C}^{+}$ は次のように表すことができる．

$$\boldsymbol{C}^{+} = (\mu-1)\boldsymbol{X}^{+}(\boldsymbol{I}+\boldsymbol{J})^{-1}(\boldsymbol{X}^{\mathrm{T}})^{+}\ . \quad \text{(A.4)}$$

このとき，

$$\boldsymbol{X}\boldsymbol{C}^{+}\boldsymbol{X}^{\mathrm{T}} = (\mu-1)\boldsymbol{X}\boldsymbol{X}^{+}(\boldsymbol{I}+\boldsymbol{J})^{-1}(\boldsymbol{X}^{\mathrm{T}})^{+}\boldsymbol{X}^{\mathrm{T}}\ . \quad \text{(A.5)}$$

今 $\boldsymbol{X}$ は full row rank であるから，その Moore-Penrose 逆行列は右逆行列であり，以下のようになる．

$$\boldsymbol{X}\boldsymbol{X}^{+} = \boldsymbol{I}\ . \quad \text{(A.6)}$$

また，容易に確認できるように $\boldsymbol{I}+\boldsymbol{J}$ の逆行列は次のようである．

$$(\boldsymbol{I}+\boldsymbol{J})^{-1} = \boldsymbol{I}-\frac{1}{\mu}\boldsymbol{J}\ . \quad \text{(A.7)}$$

(A.5) に等式 $(\boldsymbol{X}^{\mathrm{T}})^{+}\boldsymbol{X}^{\mathrm{T}} = (\boldsymbol{X}\boldsymbol{X}^{+})^{\mathrm{T}}$ および (A.6) と (A.7) を代入して，以下を得る．

$$\boldsymbol{X}\boldsymbol{C}^{+}\boldsymbol{X}^{\mathrm{T}} = (\mu-1)\left(\boldsymbol{I}-\frac{1}{\mu}\boldsymbol{J}\right)\ .$$

ここで，$\boldsymbol{X}\boldsymbol{C}^{+}\boldsymbol{X}^{\mathrm{T}}$ の ij 要素は $\boldsymbol{d}_i^{\mathrm{T}}\boldsymbol{C}^{+}\boldsymbol{d}_j$ に等しいので，$1\le i\le \mu-1$ と $1\le j\le\mu-1$ に対して以下が成立する．

$$\boldsymbol{d}_i^{\mathrm{T}}\boldsymbol{C}^{+}\boldsymbol{d}_j = \begin{cases} (\mu-1)^2/\mu & (i=j) \\ -(\mu-1)/\mu & (i\neq j)\end{cases}\ . \quad \text{(A.8)}$$

$\boldsymbol{d}_\mu$ は (A.3) のように書けるため，(A.8) は $1\le i\le\mu$ と $1\le j\le\mu$ について成り立つことがわかる．この結果 (A.8) を (A.2) に代入し，整理することで目的の式 (A.1) を得る． □

定理 1 において，$\boldsymbol{d}_1,\ldots,\boldsymbol{d}_{\mu-1}$ の線形独立性を仮定している．これは $\boldsymbol{y}_1,\ldots,\boldsymbol{y}_\mu$ が $\mu-2$ 次元以下の部分空間に含まれない限り成立する．直感的に理解できるように，集団内から $\mu\,(\le n+1)$ 個体をランダムに選択するとき，通常この仮定は満たされる．

ここで，CDP を ϵ を用いて表すと，

$$\langle\boldsymbol{x}\rangle_{\mu_\alpha}-\langle\boldsymbol{y}\rangle = \frac{1}{\mu_\alpha}\sum_{i=1}^{\mu_\alpha}\boldsymbol{x}_{i:\lambda}-\langle\boldsymbol{y}\rangle = \frac{\alpha}{\mu_\alpha}\sum_{i=1}^{\mu_\alpha}\sum_{j=1}^{\mu}\epsilon_{i:\lambda,j}\boldsymbol{d}_j = \alpha\sum_{j=1}^{\mu}\boldsymbol{d}_i(\frac{1}{\mu_\alpha}\sum_{i=1}^{\mu_\alpha}\epsilon_{i:\lambda,j}) = \alpha\sum_{j=1}^{\mu}\langle\epsilon_j\rangle_{\mu_\alpha}\boldsymbol{d}_i\ ,$$

となる．このとき，定理 1 より，

$$(\alpha\sum_{i=1}^{\mu}\langle\epsilon_i\rangle_{\mu_\alpha}\boldsymbol{d}_i)^{\mathrm{T}}\boldsymbol{C}^{+}(\alpha\sum_{i=1}^{\mu}\langle\epsilon_i\rangle_{\mu_\alpha}\boldsymbol{d}_i) = \alpha^2(k-1)(\sum_{i=1}^{\mu}\langle\epsilon_i\rangle_{\mu_\alpha}^2-\frac{1}{\mu}(\sum_{i=1}^{\mu}\langle\epsilon_i\rangle_{\mu_\alpha})^2)\ . \quad \text{(A.9)}$$

したがって，(8) が成立する．

◇ 参 考 文 献 ◇

[秋本 07] 秋本 洋平, 羽佐田 理恵, 佐久間 淳, 小野 功, 小林 重信：多親を用いた実数値 GA のための世代交代モデル Just Generation Gap (JGG) の提案と評価, 第 19 回自律分散システムシンポジウム資料, pp. 341–346 (2007)

[秋本 09] 秋本 洋平, 佐久間 淳, 小野 功, 小林 重信：機能分担 CMA-ES の提案と評価, 人工知能学会論文誌, Vol. 24, No. 1, pp. 58 – 68 (2009)

[Bosman 08] Bosman, P., Grahl, J., and Thierens, D.: Enhancing the Performance of Maximum—Likelihood Gaussian EDAs Using Anticipated Mean Shift, in *Parallel Problem Solving from Nature: PPSN X*, pp. 133–143, Berlin (2008), Springer-Verlag

[Davis 91] Davis, L.: *Handbook of Genetic Algorithms*, Van Nostrand Reinhold, New York (1991)

[Efrén 06] Efrén Mezura-Montes, Jesús Velázquez-Reyes, Coello, C. A. C.：Modified Differential Evolution for Constrained Optimization, in *Evolutionary Computation, 2006. CEC 2006. IEEE Congress on*, pp. 25–32 (2006)

[Eshelman 93] Eshelman, L.: Real-Coded Genetic Algorithms and Interval-Schemata, *Foundations of Genetic Algorithms*, Vol. 2, pp. 187–202 (1993)

[Eshelman 97] Eshelman, L. J., Mathias, K. E., and Schaffer, J. D.: Crossover Operator Biases : Exploiting the Population Distribution, in *Proceedings of the 7th International Conference on Genetic Algorithms*, pp. 354–361 (1997)

[Hansen 06] Hansen, N.: The CMA evolution strategy: a comparing review, in *Towards a new evolutionary computation. Advances on estimation of distribution algorithms*, pp. 75–102, Springer (2006)

[Harville 08] Harville, D. A.: *MATRIX ALGEBRA FROM A STATISTICIAN'S PERSPECTIVE*, Springer-Verlag (2008)

[樋口 01] 樋口 隆英, 筒井 茂義, 山村 雅幸：実数値 GA におけるシンプレックス交叉の提案, 人工知能学会論文誌, Vol. 16, No. 1, pp. 147–155 (2001)

[池田 02a] 池田 心, 小林 重信：GA の探索における UV 現象と UV 構造仮説, 人工知能学会論文誌, Vol. 17, No. 3, pp. 239–246 (2002)

[池田 02b] 池田 心, 小林 重信：生得分離モデルを用いた GA と JSP への適用, 人工知能学会論文誌, Vol. 17, No. 5, pp. 530–538 (2002)

[Kita 98] Kita, H., Ono, I., and Kobayashi, S.: Theoretical Analysis of the Unimodal Normal Distribution Crossover for Real-Coded Genetic Algorithms, in *Proceedings of the IEEE Congress on Evolutionary Computation*, pp. 529 – 534 (1998)

[Kita 99] Kita, H. and Yamamura, M.: A Function Specialization Hypothesis for Designing Genetic Algorithms, in *Proceedings of the IEEE Congress on Systems, Man and Cybernetics*, pp.

579 – 584 (1999)
[喜多 01] 喜多 一, 小野 功, 小林 重信：実数値 GA のための正規分布交叉の多数の親を用いた拡張法の提案, 計測自動制御学会論文集, Vol. 36, No. 10, pp. 875–883 (2001)
[小林 09] 小林 重信：実数値 GA のフロンティア, 人工知能学会論文誌, Vol. 24, No. 1, pp. 147 – 162 (2009)
[Liang 06] Liang, J. J. and Suganthan, P. N.: Dynamic Multi-Swarm Particle Swarm Optimizer with a Novel Constraint-Handling Mechanism, in *Evolutionary Computation, 2006. CEC 2006. IEEE Congress on*, pp. 9–16 (2006)
[Locatelli 00] Locatelli, M.: Simulated Annealing Algorithms for Continuous Global Optimization: Convergence Conditions, *Journal of Optimization Theory and Applications*, Vol. 104, No. 1, pp. 121–133 (2000)
[Ono 99a] Ono, I., Kita, H., and Kobayashi, S.: A Robust Real-Coded Genetic Algorithm using Unimodal Normal Distribution Crossover Augmented by Uniform Crossover : Effects of Self-Adaptation of Crossover Probabilities, in *Proceedings of the Genetic and Evolutionary Computation Conference, GECCO 1999*, pp. 496 –503, Morgan Kaufmann (1999)
[小野 99b] 小野 功, 佐藤 浩, 小林 重信：単峰性正規分布交叉 UNDX を用いた実数値 GA による関数最適化, 人工知能学会誌, Vol. 14, No. 6, pp. 1146–1155 (1999)
[Oshima 09] Oshima, D., Miyamae, A., Sakuma, J., Kobayashi, S., and Ono, I.: A New Real-coded Genetic Algorithm Using the Adaptive Selection Network for Detecting Multiple Optima, in *Evolutionary Computation, 2009. CEC 2009. IEEE Congress on*, pp. 1912–1919 (2009)
[Ostermeier 94] Ostermeier, A., Gawelczyk, A., and Hansen, N.: Step-Size Adaptation Based on Non-Local Use of Selection Information, in *Parallel Problem Solving from Nature - PPSN III*, pp. 189–198, Springer (1994)
[Oyman 00a] Oyman, A. I., Beyer, H.-G., and Schwefel, H.-P.: Analysis of the $(1, \lambda)$-ES on the Parabolic Ridge, *Evolutionary Computation*, Vol. 8, No. 3, pp. 249 – 265 (2000)
[Oyman 00b] Oyman, A. I., Beyer, H.-G., and Schwefel, H.-P.: Analysis of the $(\mu/\mu, \lambda)$-ES on the Parabolic Ridge, *Evolutionary Computation*, Vol. 8, No. 3, pp. 267 – 289 (2000)
[佐久間 02] 佐久間 淳, 小林 重信：実数値 GA におけるサンプリングバイアスを考慮した外挿的交叉 EDX, 人工知能学会論文誌, Vol. 17, No. 6, pp. 699–707 (2002)
[佐久間 04] 佐久間 淳, 小林 重信：高次元 k-tablet 構造を考慮した実数値 GA 隠れ変数上の交叉 LUNDX-m の提案と評価, 人工知能学会論文誌, Vol. 19, No. 1, pp. 28–37 (2004)
[Sakuma 05] Sakuma, J. and Kobayashi, S.: Latent Variable Crossover for k-tablet Structures and its Application to Lens Design Problems, in *Proceedings of the Genetic and Evolutionary Computation Conference, GECCO 2005*, pp. 1347 – 1353, ACM (2005)
[佐藤 97] 佐藤 浩, 小野 功, 小林 重信：遺伝的アルゴリズムにおける世代交代モデルの提案と評価, 人工知能学会誌, Vol. 12, No. 5, pp. 734–744 (1997)
[染谷 01] 染谷 博司, 山村 雅幸：最適解の位置にロバストな実数値 GA を実現する Toroidal Search Space Conversion の提案, 人工知能学会論文誌, Vol. 16, No. 3, pp. 333–343 (2001)
[Someya 08] Someya, H.: Theoretical Parameter Value for Appropriate Population Variance of the Distribution of Children in Real-coded GA, in *Proceedings of the IEEE Congress on Evolutionary Computation: CEC 2008 (IEEE World Congress on Computational Intelligence: WCCI 2008)*, pp. 2722 – 2729 (2008)
[Takahashi 00] Takahashi, O., Kita, H., and Kobayashi, S.: A Real-Coded Genetic Algorithm using Distance Dependent Alternation Model for Complex Function Optimization, in *Proceedings of the Genetic and Evolutionary Computation Conference, GECCO 2000*, pp. 219–226, Morgan Kaufmann (2000)
[Tsutsui 99] Tsutsui, S., Yamamura, M., and Higuchi, T.: Multi-parent Recombination with Simplex Crossover in Real Coded Genetic Algorithms, in *Proceedings of the Genetic and Evolutionary Computation Conference, GECCO 1999*, pp. 657–664, Morgan Kaufmann (1999)
[Tsutsui 00] Tsutsui, S.: Sampling Bias and Search Space Boundary Extension in Real Coded Genetic Algorithms, in *Proceedings of the Genetic and Evolutionary Computation Conference, GECCO 2000*, pp. 211–218, Morgan Kaufmann (2000)

〔担当委員：小野田 崇〕

2009 年 5 月 8 日 受理

著 者 紹 介

秋本 洋平

2007 年 3 月東京工業大学工学部情報工学科卒業，2008 年 3 月同大学総合理工学研究科知能システム科学専攻修士課程修了，2008 年 4 月同大学総合理工学研究科知能システム科学専攻博士課程入学，現在に至る．進化計算，機械学習などの研究に従事．

永田 裕一（正会員）

1994 年 9 月東京工業大学応用物理学科卒業，2000 年 3 月同大学院総合理工学研究科知能システム科学専攻博士後期課程修了．工学博士．同年 4 月同大学院総合理工学研究科リサーチアソシエイト，2001 年 4 月より北陸先端科学技術大学院大学情報科学専攻助手，2007 年 4 月より同助教，2009 年 4 月より東京工業大学大学院総合理工学研究科知能システム科学専攻助教，現在に至る．遺伝的アルゴリズム，機械学習の研究に従事．

佐久間 淳

1997 年東京工業大学生命理工学部生物工学科卒業，2003 年同大学大学院総合理工学研究科知能システム科学専攻博士後期課程修了，博士 (工学)．同年 4 月日本アイ・ビー・エム株式会社入社，東京基礎研究所に配属．2004 年 7 月，東京工業大学総合理工学研究科知能システム科学専攻助手，2007 年 4 月同助教，2009 年 4 月，筑波大学システム情報工学研究科コンピュータサイエンス専攻准教授，現在に至る．機械学習，遺伝的アルゴリズムの研究に従事．

小野 功（正会員）

1994 年 3 月東京工業大学工学部制御工学科卒業，1997 年 9 月同大学総合理工学研究科知能科学専攻博士課程修了．博士 (工学)．1997 年 10 月同研究科リサーチアソシエート，1998 年 4 月徳島大学工学部助手，1998 年 12 月同講師，2001 年 3 月同助教授，2005 年 4 月東京工業大学総合理工学研究科知能システム科学専攻助教授，現在 (准教授) に至る．進化計算，人工知能，グリッドなどの研究に従事．

小林 重信（正会員）

1974 年 3 月東京工業大学理工学研究科経営工学専攻博士課程修了．工学博士．同大学工学部制御工学科助手，総合理工学研究科システム科学専攻助教授，知能科学専攻教授等を経て，1996 年 5 月より知能システム科学専攻に移り，現在に至る．創発システム論，進化計算，強化学習などの研究に従事．